Frobenius sphere：3B 实验图表与扩展方案

数据核验：2026-10-05。16个任务均完成；本报告仅整理已有结果，没有提交新任务。

协议：width=256，28层，73.42M参数；3,000,238,080个处理tokens；11,445次更新；固定r=1；seed=1234；每组一张H20。约40.9 tokens/参数。旧width=384的初始化能量半径实验不混入本表。

主要结论

MCSD/MCSD-TP在较小学习率下领先，但按各自网格最优学习率比较，NorMuon-Sphere与MuonH略好。MCSD与MCSD-TP的最佳validation只差0.000138，尚无明确TP收益。单seed不足以判断这些小差距是否稳定。

Method	5e-3	7e-3	1e-2	1.5e-2
MCSD	3.485531	3.470591	3.467720	3.489496
MCSD-TP	3.485612	3.470890	3.467858	3.487949
MuonH	3.529123	3.500046	3.476769	3.466668
NorMuon-Sphere	3.526564	3.499072	3.476793	3.464757

表1：完整学习率网格的最终validation loss。绿色单元格表示各算法在本次网格内的最低值，不代表全局最优。

Method	Best LR	Train*	Final val	Time
MCSD	1e-2	3.444805	3.467720	18:36:00
MCSD-TP	1e-2	3.445287	3.467858	18:32:38
MuonH	1.5e-2	3.443349	3.466668	18:30:16
NorMuon-Sphere	1.5e-2	3.441753	3.464757	18:33:07

表2：Train*为更新11341-11440的在线训练均值，不是完整训练集loss。最终5步没有stdout训练loss，不能补造为step11445。时间为Slurm已分配运行时长，包含启动与评估，不含排队。

最佳NorMuon-Sphere比最佳MCSD低0.002963，MuonH低0.001052；各最佳任务耗时约18.5小时，差异不足0.6%。方法分布在不同节点，不能把很小的时间差直接归因于优化器。

1 各自最佳学习率的训练与验证曲线

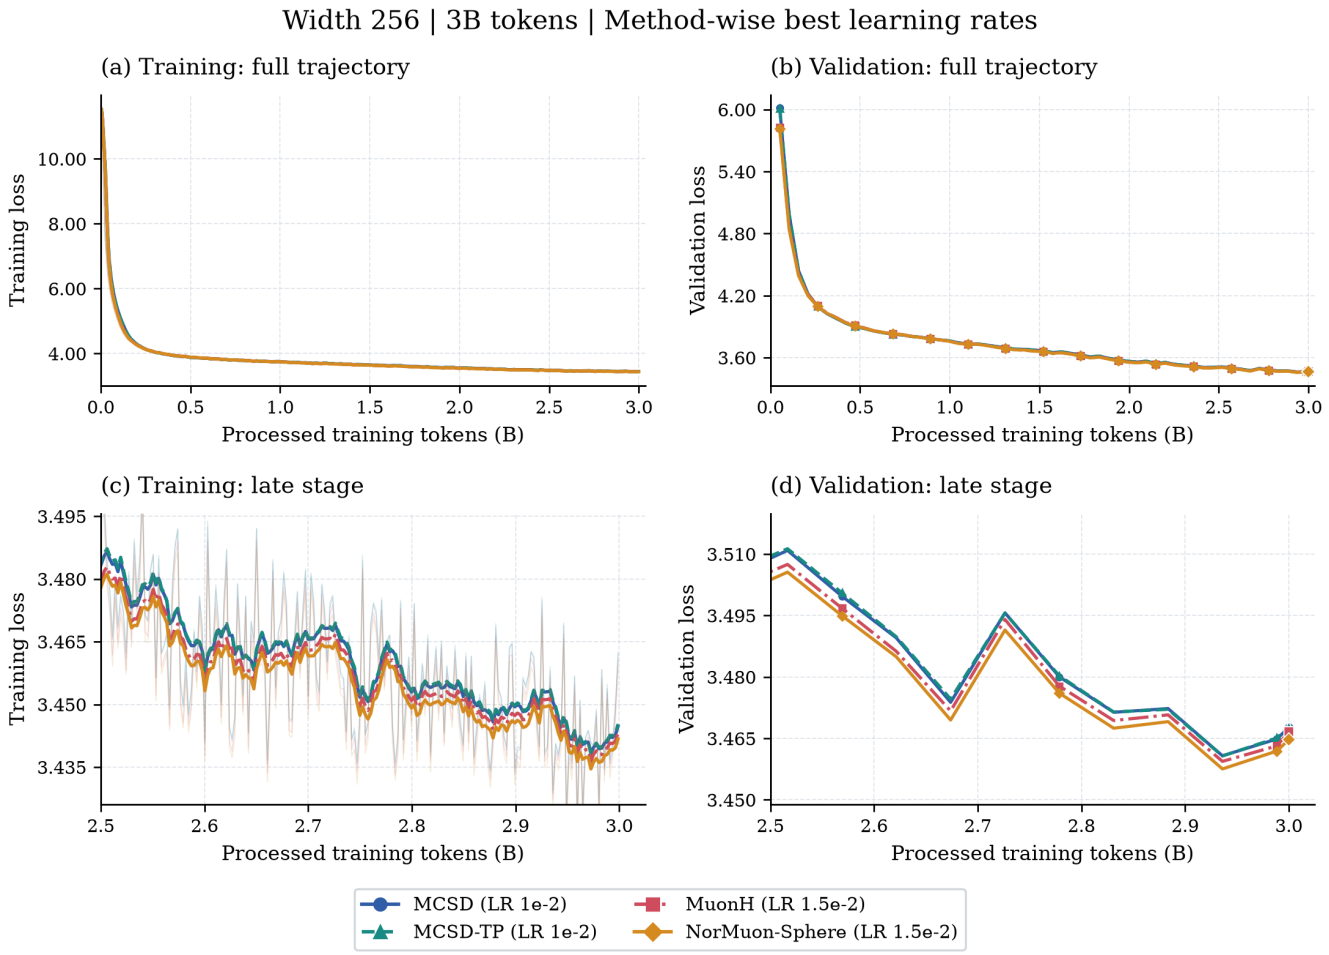


图1：按最终validation选取各算法的最佳网格学习率。MCSD/MCSD-TP使用1e-2，MuonH/NorMuon-Sphere使用1.5e-2。上排保留完整训练范围；下排放大2.5B-3B阶段。

浅色训练线为日志中的区间均值，深色线为因果100步滑动均值。验证线只连接真实评估点，不平滑、不外推。这里没有多seed置信区间；原始线的波动不是标准差。

这张图回答'给予相同四档LR搜索预算后谁更好'，不是'所有算法同一个LR时谁更好'。学习率在同一validation集上选择并报告，有选择偏差；正式结论还需要保留checkpoint、独立test集和配对seed复验。

2 学习率敏感性与训练端点

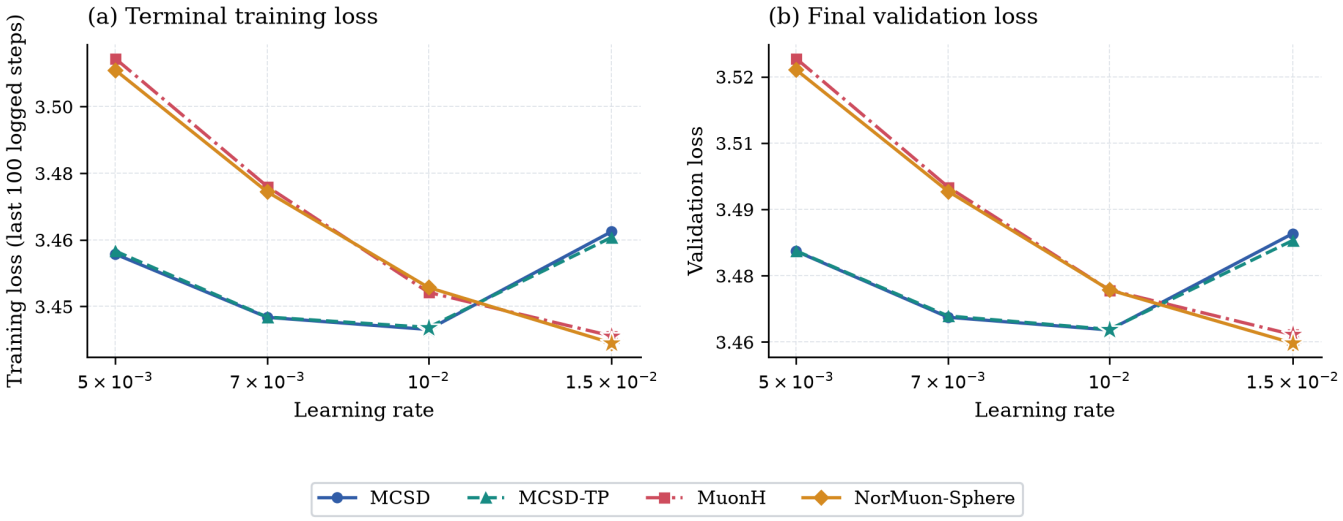


图2：左为最后100个有日志训练更新的均值，右为最终validation。星号标记各算法在每个指标上的网格最低值；横轴为对数学习率，点间直线仅用于辨识趋势。

Method	5e-3	7e-3	1e-2	1.5e-2
MCSD	3.461783	3.447546	3.444805	3.466866
MCSD-TP	3.462480	3.447613	3.445287	3.465570
MuonH	3.505829	3.476999	3.453176	3.443349
NorMuon-Sphere	3.503229	3.475798	3.454270	3.441753

MCSD类在0.015时train和validation都变差，不能仅解释成泛化问题；可能涉及更新尺度或优化动态，但当前结果不能定位原因。两条基线在最大LR仍改善，应先检查更高一档，而不是宣布当前数值为最优。

训练loss来自每10步区间平均，首条为step1；100步平滑按日志区间长度加权。末端均值由steps11350,11360,...,11440的10条日志构成，对应实际更新11341-11440。

3 全部16组的训练曲线

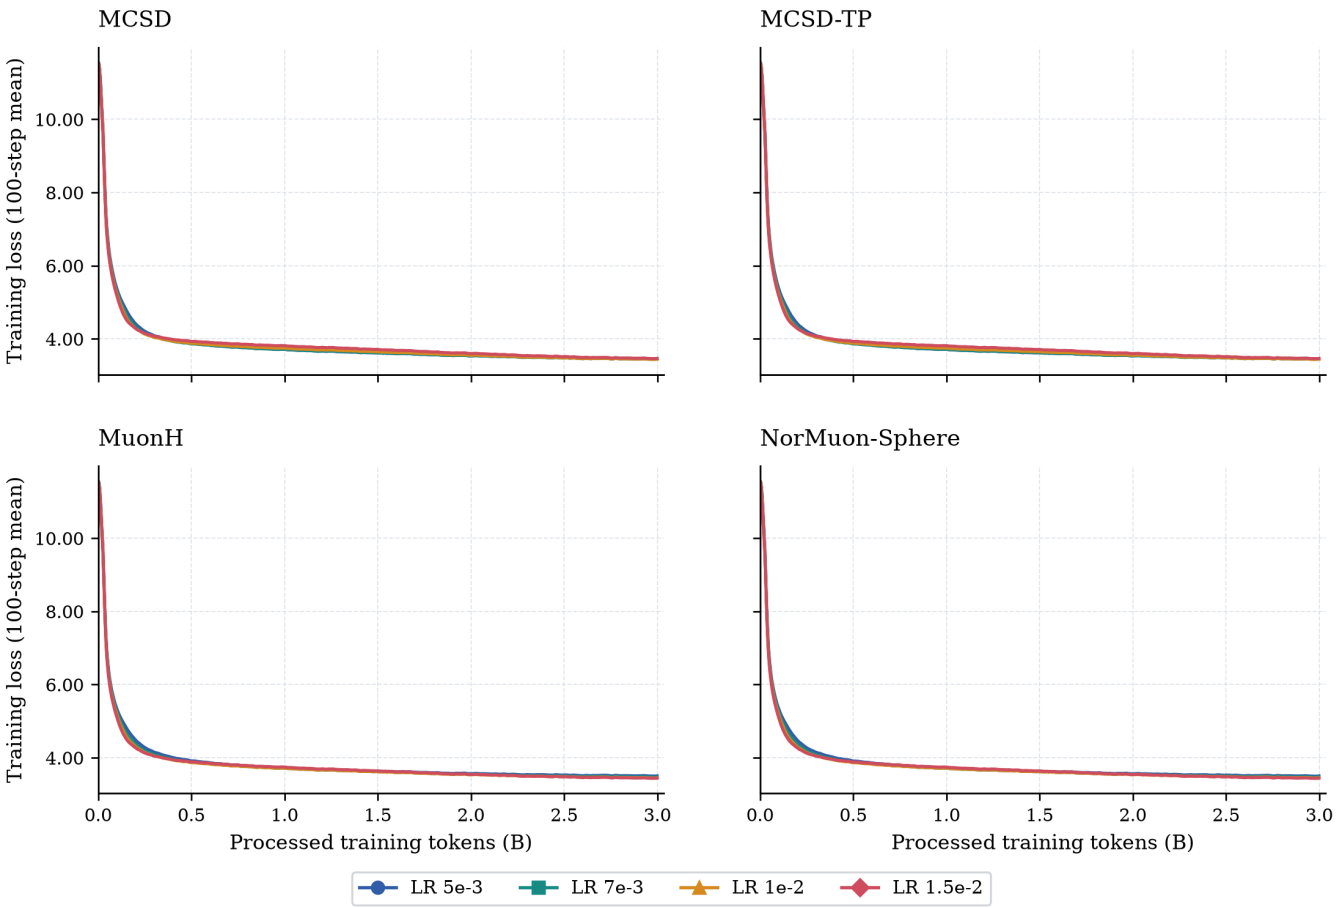


图3：每个子图一个算法，四条线为相同四档学习率。所有子图共用坐标范围；只对训练序列做100步因果滑动平均。完整原始日志点保存在配套JSON中。

不要依据早期排名取消最终比较：这轮与之前的Frobenius实验都说明，训练预算和LR都会改变观察到的排名。应预先确定预算，以同token端点或同实测算力比较。

4 全部16组的验证曲线

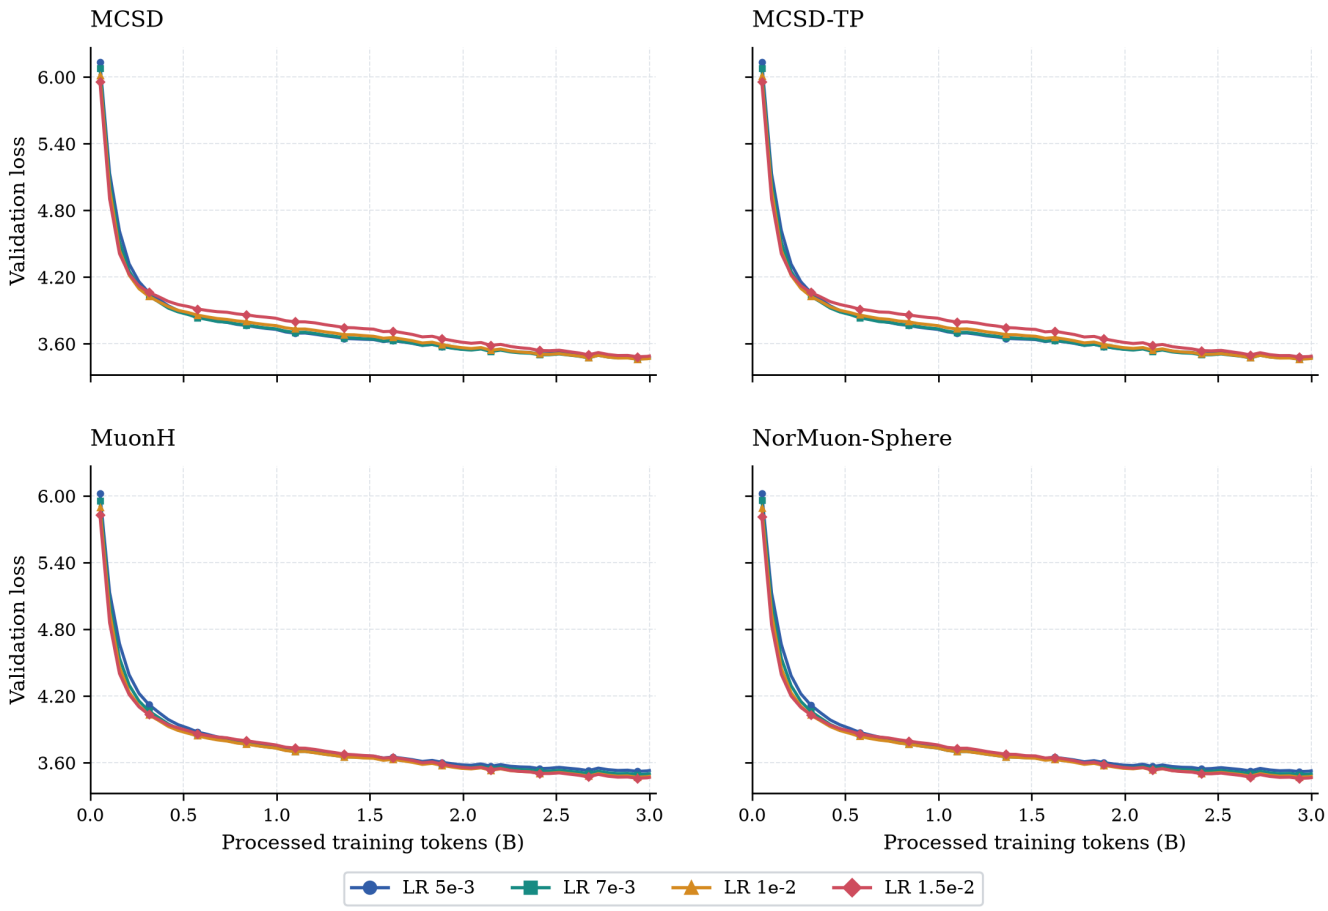


图4：每个任务含58个真实validation记录：每200步一次，至11400步，再加11445步的最终评估。所有评估点均已读取，没有只挑末端两点，也未对验证曲线平滑。

每次评估40个batch。Megatron验证迭代器会推进，因此不同训练时刻不一定评估同一批样本；本批同协议任务的对应时刻才可匹配比较。某次validation的小幅回升不等价于模型退化。

5 固定共同LR的诊断对照

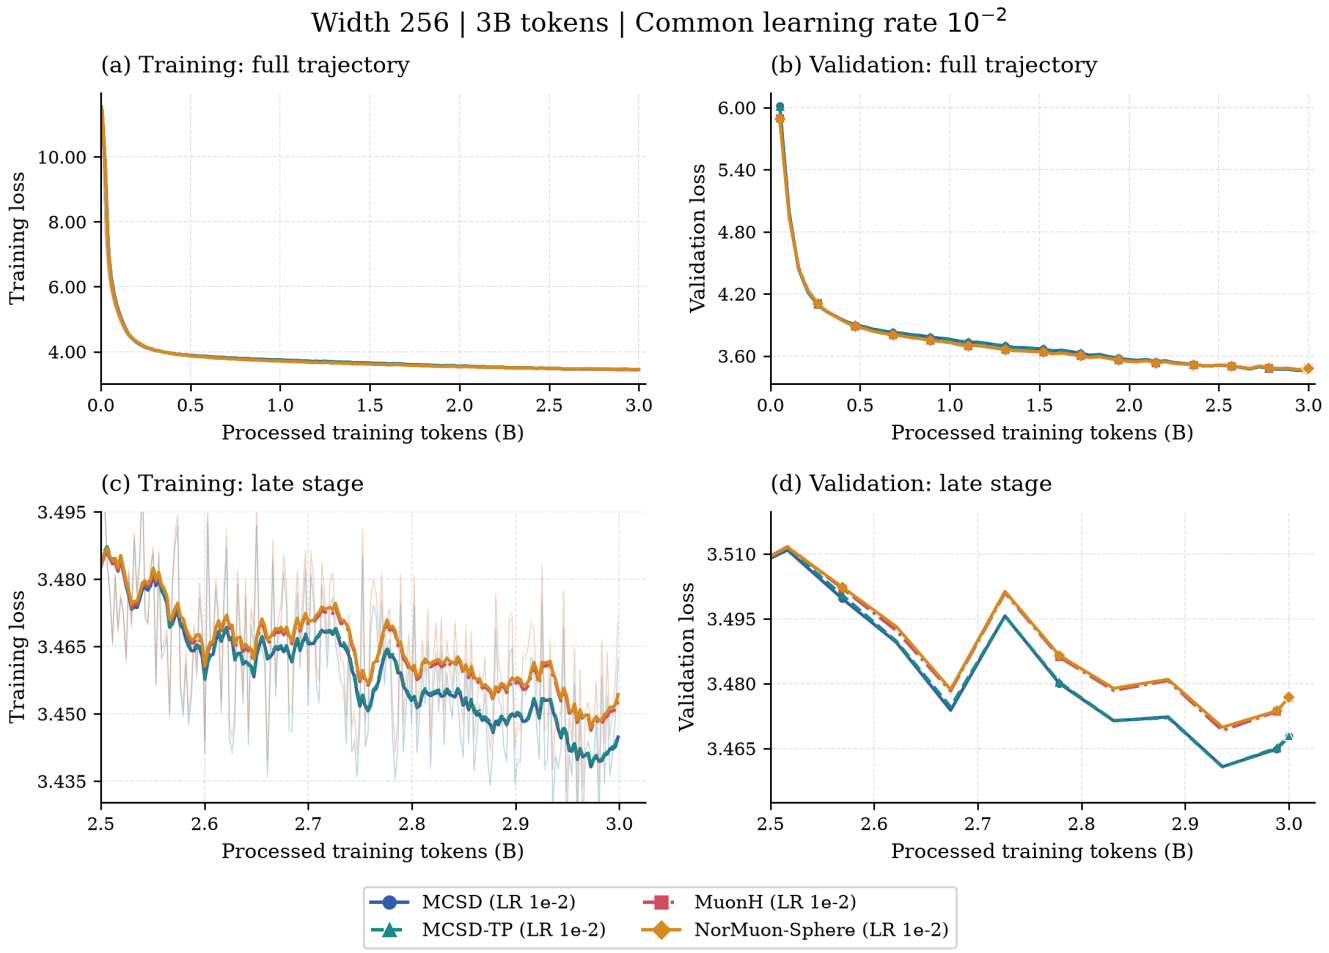


图5：所有算法固定LR=1e-2。此时MCSD/MCSD-TP优于两条基线；与图1同时展示，才能避免把LR选择优势误认为算法的普遍优势。

仍需控制：MCSD/TP是EMA beta=0.95、无Nesterov；MuonH/NorMuon-Sphere是beta=0.9、有Nesterov。辅助AdamW、模型、数据、r=1和训练预算匹配，但本轮不是'只改变切投影'的纯消融。

理论与数值：稀疏审计中的Frobenius返回误差最大约1.515e-7；这不是每步精确LMO或理论全部前提的证明。建议额外记录切向残差、LMO可行性/近似误差、相对更新范数、返回修正量和梯度裁剪频率。

6 优先补什么实验

以下是资源分阶段建议，不是已提交任务。先把Frobenius这一条线做扎实，再扩展另外两种几何；不要一次性把全部几何、规模、LR和seed做成乘积网格。

阶段	配置与新增任务	回答的问题
A LR边界	width256 / 3B；四算法各补LR=2e-2，共4组	基线最优是否仍在当前上边界之外？
B 配对复验	冻结各自选择的LR；新增2个共同seed，4×2=8组	约0.001-0.003的差距是否可重复？
C 宽度迁移	width384、512 / 3B；直接迁移256的LR，4×2=8组	无需重调LR时，扩大模型后表现如何？
D 同预算重调	同两种新width；每算法再测共同网格的其余3档，增24组	迁移损失相对该规模最佳LR有多大？

D阶段的共同四档网格可暂定{7e-3,1e-2,1.5e-2,2e-2}；须先完成A确认最优点被包住。若A仍呈边界下降，应统一扩展后再冻结。8组迁移任务必须落在随后网格中，否则不能直接按'再加24组'计数。

宽度迁移固定：28层、head维度64、FFN=3d、GQA比例、序列2048、batch128、r=1、精度与辅助AdamW规则。width256约73.42M、384约126.64M；512需以真实模型实例计数，不能沿用旧架构参数量。旧width384半径协议不同，必须重跑。

计划输出：width×LR星点连接图；固定256所选LR的loss-vs参数量图；迁移LR与逐规模重调最佳LR的loss差（transfer regret）。超参数迁移不等同于compute-optimal scaling。[1]

固定shape半径不自动证明μP迁移性。扩规模前还应审计embedding/readout初始化、辅助学习率与矩阵fan-in/out缩放规则，并记录真实参数量及更新尺度。

资源：按当前width256约18.5小时/组，A+B共12组约222 H20小时，4卡纯运行约2.3天（不含排队，若旧seed不能复用则需额外4组）。更宽模型先测吞吐再估时；维持4卡并发，最多6卡且给其他用户留余量。

7 真正的scaling实验与论文边界

固定tokens的宽度实验 ≠ scaling law拟合

只在一个模型、一个3B预算上扫LR，只能证明该设定的调参表现。第一步可报告宽度迁移；若要研究参数量与数据量的联合标度，再设计N×D二维网格。Chinchilla分别比较不同训练预算及固定FLOPs下的配置，不是依据固定tokens/参数阈值判断'充分训练'。[2]

建议小规模起步：width∈{256,384,512}，D∈{0.75B,1.5B,3B}。四算法每格一个seed共36个配置；若三种width的3B迁移组已完成且协议冻结，可以复用12个，新增24个短预算配置。3个宽度、9个端点只能做初步趋势分析，不足以可靠外推大模型标度指数。

关键：每个D都从初始化训练，warmup和cosine按该D重新定义。不能截取3B轨迹在0.75B/1.5B的位置，伪装成独立短预算实验；其LR调度阶段不同。Chinchilla明确讨论了这一偏差。[2, Sec. 2]

固定算力与数据限制

分别报告处理tokens、真实参数量（含/不含embedding）、训练FLOPs估计以及实测H20小时。6ND只作粗略计算量代理，不能覆盖所有注意力及优化器成本；固定token比较不是固定compute比较。正式拟合应扩大N/D跨度，预留未参与拟合的模型/预算点，并报告不确定性。

当前3B/73.42M≈40.9，不支持直接把本轮差距归因于'tokens/参数不足'；比例不是收敛或最优性的充分条件。数据仅3B时可另外研究6B/12B重复训练，但必须区分unique tokens与processed tokens，不能当成6B/12B新数据。重复数据的边际收益需单独建模。[3]

论文中的可支持结论

当前：一个尺度、一个seed、同预算LR搜索的实际表现；尚不能声称普遍优于基线、满足所有理论前提或改变了scaling exponent。补足宽度迁移、配对seed、固定数值精度及动量的机制消融、独立评估和耗时，再讨论跨规模优势。

优先机制消融：width256/3B，LR∈{1e-2,1.5e-2}，两套动量（0.95/无Nesterov与0.9/有Nesterov）×四算法，共16格；当前可复用8格，再补交叉设置的8格。这样能区分算法方向与动量配方的影响，且不改算法定义。

参考文献

[1] Yang et al. Tensor Programs V: Tuning Large Neural Networks via Zero-Shot Hyperparameter Transfer. arXiv:2203.03466.
[2] Hoffmann et al. Training Compute-Optimal Large Language Models. arXiv:2203.15556.
[3] Muennighoff et al. Scaling Data-Constrained Language Models. arXiv:2305.16264.